

Scraper | Site Anvisa de Alertas e Notificações

```
from pathlib import Path

DATASET_DIR = '/dataset'

ROOT_DIR = Path().resolve().__str__()
DATASET_PATH = ROOT_DIR + DATASET_DIR
DATASET_FILENAME = 'Anvisa_Alertas_2026-01-01_2026-06-19_.csv'
DATASET_FILEPATH = Path(ROOT_DIR + DATASET_DIR + '/' + DATASET_FILENAME)
Path.mkdir(Path(DATASET_PATH), parents=True, exist_ok=True)
```

```

from bs4 import BeautifulSoup
import re

url = "https://antigo.anvisa.gov.br/alertas/-/buscar?
p_p_id=anvisabuscaavancada_WAR_anvisabuscaavancadaportlet&keywords=&dataInicial=01/01
/2016&dataFinal=19/06/2026&categoryIds=34506&categoryIds=5396434&categoryIds=5396432&categ
oryIds=34509&categoryIds=34510&categoryIds=34511"
page = "&pagina="
url_paginated = url+page

def scrap(url: str):
    scrapper = cs.create_scraper()
    res = scrapper.get(url)
    return res, BeautifulSoup(res.text, "html.parser")

res, soup = scrap(url)

alertas = soup.find_all(name='p', attrs={'class': 'titulo'})

# URLs
links = [alerta.find('a', href=True)['href'] for alerta in alertas]

# Titulo
titulos = [alerta.text.strip() for alerta in alertas]

# Data
def data(soup: BeautifulSoup):
    datas = soup.find_all('p', attrs={'class': 'data'})
    datas = [data.text.strip() for data in datas]
    datas = filter(lambda d: re.search(r"[a-z]", d) is None, datas)
    datas = list(datas)
    return datas

datas = data(soup)

# Paginação
pagination = soup.find_all(name='li', attrs={'class': 'pagination-control'})

last_page = max([int(page.find('a')['data-pagination'] if page.find('a')['data-pagination']
) != '' else '0') for page in pagination])
next_page = 1

```

```

while next_page < last_page:
    next_page = next_page + 1
    res, soup = scrap(url_paginated+str(next_page))

    if res.status_code != 200:
        error_msg = f"Response code: {res.status_code} | Reason: {res.reason} | URL: {
url_paginated+str(next_page)}"
        print(f"Response code: {res.status_code} | Reason: {res.reason} | URL: {
url_paginated+str(next_page)}")
        links.append(error_msg)
        titulos.append(error_msg)
        datas.append(error_msg)
    else:
        alertas = soup.find_all(name='p', attrs={'class': 'titulo'})
        _titulos = [alerta.text.strip() for alerta in alertas]
        titulos.extend(_titulos)

```

```
import pandas as pd
```

```

df = pd.DataFrame(data={'titulo': titulos, 'data': datas, 'url': links})
df

```

	titulo	data	url
0	Alerta 5265 (Tecnovigilância) - Comunicado da ...	16/06/2026	http://antigo.anvisa.gov.br/informacoes-tecnic...
1	Alerta 5264 (Tecnovigilância) - Comunicado da ...	16/06/2026	http://antigo.anvisa.gov.br/informacoes-tecnic...
2	Alerta 5263 (Tecnovigilância) - Comunicado da ...	16/06/2026	http://antigo.anvisa.gov.br/informacoes-tecnic...
3	Alerta 5262 (Tecnovigilância) - Comunicado da ...	16/06/2026	http://antigo.anvisa.gov.br/informacoes-tecnic...
4	Alerta 5261 (Tecnovigilância) - Comunicado da ...	16/06/2026	http://antigo.anvisa.gov.br/informacoes-tecnic...
...	...	...	...
3514	Alerta 1789 Atualizado (Tecnovigilância) - GE ...	13/01/2016	http://antigo.anvisa.gov.br/informacoes-tecnic...
3515	Alerta 1788	12/01/2016	http://antigo.anvisa.gov.br/informacoes-tecnic...
3516	Alerta 1787	12/01/2016	http://antigo.anvisa.gov.br/informacoes-tecnic...
3517	Alerta 1780	06/01/2016	http://antigo.anvisa.gov.br/informacoes-tecnic...
3518	Alerta 1779	06/01/2016	http://antigo.anvisa.gov.br/informacoes-tecnic...

3519 rows × 3 columns

```
df.to_csv(DATASET_FILEPATH, index=False, encoding='utf-8')
```

```

links = [alerta.find('a', href=True)['href'] for alerta in alertas]
datas = soup.find_all('p', attrs={'class': 'data'})

```

```

import cloudscraper as cs

scraper = cs.create_scraper()

def retrieve_content(_url: str):
    res = scraper.get(_url)

    if res.status_code != 200:
        print(f"Response code: {res.status_code} | URL: {_url}")
        return res.status_code

    html = res.text
    soup = BeautifulSoup(html, "html.parser")
    content = soup.find('div', attrs={'class': 'journal-content-article'})
    return content.text

c_content = [retrieve_content(url) for url in df['url']]

```

```

df = pd.DataFrame(data={'titulo': df['titulo'], 'url': df['url'], 'content': c_content})
df

```

	titulo	url	
0	Alerta 5265 (Tecnovigilância) - Comunicado da ...	http://antigo.anvisa.gov.br/informacoes-tecnic...	Área: GGMOI
1	Alerta 5264 (Tecnovigilância) - Comunicado da ...	http://antigo.anvisa.gov.br/informacoes-tecnic...	Área: GGMOI
2	Alerta 5263 (Tecnovigilância) - Comunicado da ...	http://antigo.anvisa.gov.br/informacoes-tecnic...	Área: GGMOI
3	Alerta 5262 (Tecnovigilância) - Comunicado da ...	http://antigo.anvisa.gov.br/informacoes-tecnic...	Área: GGMOI
4	Alerta 5261 (Tecnovigilância) - Comunicado da ...	http://antigo.anvisa.gov.br/informacoes-tecnic...	Área: GGMOI
...	...	...	
3514	Alerta 1789 Atualizado (Tecnovigilância) - GE ...	http://antigo.anvisa.gov.br/informacoes-tecnic...	Área: GGMOI
3515	Alerta 1788	http://antigo.anvisa.gov.br/informacoes-tecnic...	Área: GGMOI
3516	Alerta 1787	http://antigo.anvisa.gov.br/informacoes-tecnic...	Área: GGMOI
3517	Alerta 1780	http://antigo.anvisa.gov.br/informacoes-tecnic...	Área: GGMOI
3518	Alerta 1779	http://antigo.anvisa.gov.br/informacoes-tecnic...	Área: GGMOI

3519 rows × 3 columns

```

duplicateRows_content = df[df.duplicated(['content'])]

```

```
duplicateRows_titulo = df[df.duplicated(['titulo'])]
duplicateRows_titulo
```

	titulo	url	
1070	Alerta 4227 (Tecnovigilância) - Comunicado da ...	http://antigo.anvisa.gov.br/informacoes-tecnic...	Área: GGM
1800	ALERTA: Anvisa alerta os profissionais de saúd...	http://antigo.anvisa.gov.br/informacoes-tecnic...	Área: GGM
3368	Siemens - Sistema de Ultrassom Diagnóstico ACU...	http://antigo.anvisa.gov.br/informacoes-tecnic...	Área: GGM

```
dupes = []
for titulo in duplicateRows_titulo['titulo']:
    dupes.append(df.query('titulo == "' + titulo + '"')[['titulo', 'url', 'content']])
```

dupes[0]

	titulo	url	
1069	Alerta 4227 (Tecnovigilância) - Comunicado da ...	http://antigo.anvisa.gov.br/informacoes-tecnic...	Área: GGMOI
1070	Alerta 4227 (Tecnovigilância) - Comunicado da ...	http://antigo.anvisa.gov.br/informacoes-tecnic...	Área: GGMOI

dupes[1]

	titulo	url	
1744	ALERTA: Anvisa alerta os profissionais de saúd...	http://antigo.anvisa.gov.br/informacoes-tecnic...	Área: GGMO
1800	ALERTA: Anvisa alerta os profissionais de saúd...	http://antigo.anvisa.gov.br/informacoes-tecnic...	Área: GGMO

dupes[2]

	titulo	url	
3367	Siemens - Sistema de Ultrassom Diagnóstico ACU...	http://antigo.anvisa.gov.br/informacoes-tecnic...	Área: GGM
3368	Siemens - Sistema de Ultrassom Diagnóstico ACU...	http://antigo.anvisa.gov.br/informacoes-tecnic...	Área: GGM

```
df.to_csv(DATASET_FILEPATH, index=False, encoding='utf-8')
```