

Scraper | Site Anvisa de Registro e Notificações de Medicamentos

Definição de Variáveis

```
from pathlib import Path

DATASET_DIR = 'samples/dataset'
DATASET_FILENAME = 'Anvisa_REGISTRO_MEDICAMENTOS.csv'

ROOT_DIR = Path().resolve().__str__()
DATASET_PATH = ROOT_DIR + '/' + DATASET_DIR
Path.mkdir(Path(DATASET_PATH), parents=True, exist_ok=True)
DATASET_FILEPATH = Path(DATASET_PATH + '/' + DATASET_FILENAME)
TOTAL_ELEMENTS = 50000
```

Definição da request

```
url = "https://consultas.anvisa.gov.br/api/consulta/medicamento/produtos/"
```

```
headers = {
    "User-Agent": "Mozilla/5.0 (Windows NT 10.0; Win64; x64; rv:152.0) Gecko/20100101 Firefox/152.0",
    "Accept": "application/json, text/plain, */*",
    "Accept-Language": "en-US,en;q=0.9",
    "Accept-Encoding": "gzip, deflate, br, zstd",
    "If-Modified-Since": "Mon, 26 Jul 1997 05:00:00 GMT",
    "Cache-Control": "no-cache",
    "Pragma": "no-cache",
    "Authorization": "Guest",
    "x-dtpc": "4$266473457_314h85vLUAVIHKFRGMWAOEQDL0VUGPFNFINOJVM-0e0",
    "x-dtreferer": "https://consultas.anvisa.gov.br/",
    "Connection": "keep-alive",
    "Referer": "https://consultas.anvisa.gov.br/",
    "Sec-Fetch-Dest": "empty",
    "Sec-Fetch-Mode": "cors",
    "Sec-Fetch-Site": "same-origin",
    "Priority": "u=0",
}
```

```

params = [
    {
        "column": "",
        "count": TOTAL_ELEMENTS,
        "filter[checkNotificado]": "true", # Notificado
        "filter[checkRegistrado]": "true",
        "filter[situacaoRegistro]": "V", # Ativo
        "order": "asc",
        "page": 1,
    },
    {
        "column": "",
        "count": TOTAL_ELEMENTS,
        "filter[checkNotificado]": "true", # Notificado
        "filter[checkRegistrado]": "true",
        "filter[situacaoRegistro]": "C", # Inativo
        "order": "asc",
        "page": 1,
    },
]

```

Execução da Request

```

import cloudscraper as cs

try:
    scrapper = cs.create_scraper()
    responses = [scrapper.get(url, params=param, headers=headers) for param in params]

    print(f'Raw data retrieved from {url}')

except cs.exceptions.CaptchaException as e:
    print(e)

```

Raw data retrieved from <https://consultas.anvisa.gov.br/api/consulta/medicamento/produtos/>

Tratamento dos dados

```

medicacao = []
dataVencimentoRegistro = []
situacaoApresentacao = []
categoriaRegulatoriaDescricao = []
categoriaRegulatoriaCategoria = []
tipoAutorizacao = []
razaoSocial = []
cnpjFormatado = []
numeroProcessoFormatado = []

```

```

import json

for response_json in responses:
    response_json = json.loads(response_json.text)
    for item in response_json['content']:
        produto = dict(item['produto'])
        medicacao.append(produto['nome'])
        situacaoApresentacao.append(produto['situacaoApresentacao'])
        dataVencimentoRegistro.append(str(produto['dataVencimentoRegistro']).split('T')[0])

    categoriaRegulatoriaDescricao.append(produto['categoriaRegulatoria']['descricao'])
    categoriaRegulatoriaCategoria.append(produto['categoriaMedicamentoNotificado'])
    tipoAutorizacao.append(produto['tipoAutorizacao'])

    empresa = dict(item['empresa'])
    razaoSocial.append(empresa['razaoSocial'])
    cnpjFormatado.append(empresa['cnpjFormatado'])

    processo = dict(item['processo'])
    numeroProcessoFormatado.append(item['processo']['numeroProcessoFormatado'])

```

```

import pandas as pd

df = pd.DataFrame(data={'medicamento': medicacao,
                        'situacao': situacaoApresentacao,
                        'data_Vencimento_Registro': dataVencimentoRegistro,
                        'categoria_Regulatoria_Descricao': categoriaRegulatoriaDescricao,
                        'tipo_Autorizacao': tipoAutorizacao,
                        'razao_Social': razaoSocial,
                        'cnpj_Formatado': cnpjFormatado,
                        'numero_Processo_Formatado': numeroProcessoFormatado,
                        })

```

Exibição das Informações

```
docs = [row[1].to_markdown(tablefmt=None) for row in df.iterrows()]

```

```
print('\n'.join(docs[:5]))
```

0

```
-----  
medicamento      IROSÊ  
situacao          Ativo  
data_Vencimento_Registro  2033-08-01  
categoria_Regulatoria_Descricao  Similar  
tipo_Autorizacao  REGISTRADO  
razao_Social      ALTHAIA S.A. INDUSTRIA FARMACEUTICA  
cnpj_Formatado    48.344.725/0007-19  
numero_Processo_Formatado  25351.305631/2023-68
```

1

```
-----  
medicamento      SOLIQUA  
situacao          Ativo  
data_Vencimento_Registro  2027-07-01  
categoria_Regulatoria_Descricao  Biológico  
tipo_Autorizacao  REGISTRADO  
razao_Social      SANOFI MEDLEY FARMACÊUTICA LTDA.  
cnpj_Formatado    10.588.595/0010-92  
numero_Processo_Formatado  25351.411883/2019-49
```

2

```
-----  
medicamento      ARCALION  
situacao          Ativo  
data_Vencimento_Registro  2026-12-01  
categoria_Regulatoria_Descricao  Novo  
tipo_Autorizacao  REGISTRADO  
razao_Social      LABORATÓRIOS SERVIER DO BRASIL LTDA  
cnpj_Formatado    42.374.207/0001-76  
numero_Processo_Formatado  25992.016621/74
```

3

```
-----  
medicamento      CLORIDRATO DE TERBINAFINA  
situacao          Ativo  
data_Vencimento_Registro  2027-10-01  
categoria_Regulatoria_Descricao  Genérico  
tipo_Autorizacao  REGISTRADO  
razao_Social      EMS S/A  
cnpj_Formatado    57.507.378/0003-65  
numero_Processo_Formatado  25351.028936/01-28
```

4

```
-----  
medicamento      COSARTAN ALP  
situacao          Ativo  
data_Vencimento_Registro  2028-11-01  
categoria_Regulatoria_Descricao  Similar  
tipo_Autorizacao  REGISTRADO  
razao_Social      GERMED FARMACEUTICA LTDA  
cnpj_Formatado    45.992.062/0001-65  
numero_Processo_Formatado  25351.447535/2012-63
```

Exportação para CSV

```
df.to_csv(DATASET_FILEPATH, index=False, encoding='utf-8')
```

Checksum

```
import hashlib  
print(f'{DATASET_FILEPATH.name}: {hashlib.md5(open(DATASET_FILEPATH, 'rb').read()).  
hexdigest()}')
```

```
Anvisa_REGISTRO_MEDICAMENTOS.csv: fa7c0dbc84662750bf5e1468aae9b6e9
```