

Scraper | Site Anvisa de Registro e Notificações de Medicamentos

Definição de Variáveis

```
from pathlib import Path

DATASET_DIR = 'samples/dataset'
DATASET_FILENAME = 'Anvisa_REGISTRO_MEDICAMENTOS.csv'

ROOT_DIR = Path().resolve().__str__()
DATASET_PATH = ROOT_DIR + '/' + DATASET_DIR
Path.mkdir(Path(DATASET_PATH), parents=True, exist_ok=True)
DATASET_FILEPATH = Path(DATASET_PATH + '/' + DATASET_FILENAME)
TOTAL_ELEMENTS = 50000
```

Definição da request

```
url = "https://consultas.anvisa.gov.br/api/consulta/medicamento/produtos/"
```

```
headers = {
    "User-Agent": "Mozilla/5.0 (Windows NT 10.0; Win64; x64; rv:152.0) Gecko/20100101 Firefox/152.0",
    "Accept": "application/json, text/plain, */*",
    "Accept-Language": "en-US,en;q=0.9",
    "Accept-Encoding": "gzip, deflate, br, zstd",
    "If-Modified-Since": "Mon, 26 Jul 1997 05:00:00 GMT",
    "Cache-Control": "no-cache",
    "Pragma": "no-cache",
    "Authorization": "Guest",
    "x-dtpc": "4$266473457_314h85vLUAVIHKFRGMWAOEQDLOVUGPFNFINOJVM-0e0",
    "x-dtreferer": "https://consultas.anvisa.gov.br/",
    "Connection": "keep-alive",
    "Referer": "https://consultas.anvisa.gov.br/",
    "Sec-Fetch-Dest": "empty",
    "Sec-Fetch-Mode": "cors",
    "Sec-Fetch-Site": "same-origin",
    "Priority": "u=0",
}
```

```

params = [
    {
        "column": "",
        "count": TOTAL_ELEMENTS,
        "filter[checkNotificado]": "true", # Notificado
        "filter[checkRegistrado]": "true",
        "filter[situacaoRegistro]": "V", # Ativo
        "order": "asc",
        "page": 1,
    },
    {
        "column": "",
        "count": TOTAL_ELEMENTS,
        "filter[checkNotificado]": "true", # Notificado
        "filter[checkRegistrado]": "true",
        "filter[situacaoRegistro]": "C", # Inativo
        "order": "asc",
        "page": 1,
    },
]

```

Execução da Request

```

import cloudscraper as cs

try:
    scrapper = cs.create_scraper()
    responses = [scrapper.get(url, params=param, headers=headers) for param in params]

    print(f'Raw data retrieved from {url}')
    print(f'{len([responses])} page(s) found.')

except cs.exceptions.CaptchaException as e:
    print(e)

```

Raw data retrieved from <https://consultas.anvisa.gov.br/api/consulta/medicamento/produtos/>
2 page(s) found.

Tratamento dos dados

```

codigo = []
medicacao = []
dataVencimentoRegistro = []
situacaoApresentacao = []
categoriaRegulatoriaDescricao = []
categoriaRegulatoriaCategoria = []
tipoAutorizacao = []
razaoSocial = []
cnpjFormatado = []
numeroProcessoFormatado = []
url = []

```

```

import json

for response_json in responses:
    response_json = json.loads(response_json.text)
    for item in response_json['content']:

        produto = dict(item['produto'])
        codigo.append(produto['codigo'])
        medicacao.append(produto['nome'])
        situacaoApresentacao.append(produto['situacaoApresentacao'])
        dataVencimentoRegistro.append(str(produto['dataVencimentoRegistro']).split('T')[0])

        categoriaRegulatoriaDescricao.append(produto['categoriaRegulatoria']['descricao'])
        categoriaRegulatoriaCategoria.append(produto['categoriaMedicamentoNotificado'])
        tipoAutorizacao.append(produto['tipoAutorizacao'])
        url.append(f'https://consultas.anvisa.gov.br/#/medicamentos/{produto['codigo']}')

        empresa = dict(item['empresa'])
        razaoSocial.append(empresa['razaoSocial'])
        cnpjFormatado.append(empresa['cnpjFormatado'])

        processo = dict(item['processo'])
        numeroProcessoFormatado.append(item['processo']['numeroProcessoFormatado'])

```

```

import pandas as pd

df = pd.DataFrame(data={
    'codigo': codigo,
    'medicamento': medicacao,
    'situacao': situacaoApresentacao,
    'data_Vencimento_Registro': dataVencimentoRegistro,
    'categoria_Regulatoria_Descricao': categoriaRegulatoriaDescricao,
    'tipo_Autorizacao': tipoAutorizacao,
    'razao_Social': razaoSocial,
    'cnpj_Formatado': cnpjFormatado,
    'numero_Processo_Formatado': numeroProcessoFormatado,
    'url': url,
})

```

Exibição das Informações

```
docs = [row[1].to_markdown(tablefmt=None) for row in df.iterrows()]
```

```
print('\n'.join(docs[:5]))
```

```
----- 0 -----
codigo      1098085
medicamento sinvastatina
situacao     Ativo
data_Vencimento_Registro 2036-04-01
categoria_Regulatoria_Descricao Genérico
tipo_Autorizacao REGISTRADO
razao_Social NOVARTIS BIOCIENCIAS S.A
cnpj_Formatado 56.994.502/0001-30
numero_Processo_Formatado 25351.916068/2016-29
url          https://consultas.anvisa.gov.br/#/medicamentos/1098085
----- 1 -----
codigo      466454
medicamento AMATO
situacao     Ativo
data_Vencimento_Registro 2026-11-01
categoria_Regulatoria_Descricao Similar
tipo_Autorizacao REGISTRADO
razao_Social EUROFARMA LABORATORIOS S.A.
cnpj_Formatado 61.190.096/0001-92
numero_Processo_Formatado 25351.299730/2005-11
url          https://consultas.anvisa.gov.br/#/medicamentos/466454
----- 2 -----
codigo      56508
medicamento cyfenol
situacao     Ativo
data_Vencimento_Registro 2034-11-01
categoria_Regulatoria_Descricao BAIXO RISCO
tipo_Autorizacao NOTIFICADO
razao_Social CIFARMA CIENTÍFICA FARMACÊUTICA LTDA
cnpj_Formatado 17.562.075/0001-69
numero_Processo_Formatado
url          https://consultas.anvisa.gov.br/#/medicamentos/56508
----- 3 -----
codigo      1376475
medicamento letrozol
situacao     Ativo
data_Vencimento_Registro 2032-01-01
categoria_Regulatoria_Descricao Genérico
tipo_Autorizacao REGISTRADO
razao_Social BLAU FARMACÊUTICA S.A.
```

cnpj_Formatado	58.430.828/0001-60
numero_Processo_Formatado	25351.706651/2019-76
url	https://consultas.anvisa.gov.br/#/medicamentos/13764754

codigo	520950
medicamento	ACETILCISTEÍNA
situacao	Ativo
data_Vencimento_Registro	2027-09-01
categoria_Regulatoria_Descricao	Genérico
tipo_Autorizacao	REGISTRADO
razao_Social	GEOLAB INDÚSTRIA FARMACÊUTICA S/A
cnpj_Formatado	03.485.572/0001-04
numero_Processo_Formatado	25351.100546/2007-95
url	https://consultas.anvisa.gov.br/#/medicamentos/520950

Exportação para CSV

```
df.to_csv(DATASET_FILEPATH, index=False, encoding='utf-8')
```

Checksum

```
import hashlib
print(f'{DATASET_FILEPATH.name}: {hashlib.md5(open(DATASET_FILEPATH, 'rb').read()).hexdigest()}')
```

Anvisa_REGISTRO_MEDICAMENTOS.csv: 6f6ec84bf01c4014432dd3047a4649e7